Πανεπιστήμιο Πειραιώς, Τμήμα Πληροφορικής
Προπτυχιακό Πρόγραμμα Σπουδών
Ακαδ. έτος 2025-26 (εαρινό εξάμηνο)

ΑΝΑΛΥΤΙΚΗ ΔΕΔΟΜΕΝΩΝ

Απαλλακτική Εργασία (ομάδες των 1-2 ατόμων)

ΜΠΚΕΔ2544 – Δημήτρης Σωτηρόπουλος – mpked2544@unipi.gr

Πίνακας περιεχομένων

1. TASK 01 – ΔΗΜΙΟΥΡΓΊΑ ΒΆΣΗΣ ΔΕΔΟΜΈΝΩΝ ΚΑΙ ΦΌΡΤΩΣΗ ΔΕΔΟΜΈΝΩΝ..... 2
2. TASK 02 – ΔΗΜΙΟΥΡΓΊΑ ΓΕΩΜΕΤΡΙΚΏΝ ΣΗΜΕΊΩΝ PICKUP ΚΑΙ DROPOFF 2
3. TASK 03 – ΦΙΛΤΡΆΡΙΣΜΑ ΕΓΓΡΑΦΏΝ ΕΚΤΌΣ ΤΟΥ BOUNDING BOX ΤΗΣ ΝΈΑΣ ΥΌΡΚΗΣ3
4. TASK 04 – ΑΦΑΊΡΕΣΗ ΕΓΓΡΑΦΏΝ ΜΕ ΛΑΝΘΑΣΜΈΝΗ ΧΡΟΝΙΚΉ ΣΕΙΡΆ..... 4
5. TASK 05 – ΑΦΑΊΡΕΣΗ ΔΙΠΛΌΤΥΠΩΝ ΚΑΙ ΣΧΕΔΌΝ ΔΙΠΛΌΤΥΠΩΝ ΕΓΓΡΑΦΏΝ 4
6. TASK 06 – ΑΦΑΊΡΕΣΗ ΕΓΓΡΑΦΏΝ ΜΕ ΜΗ ΡΕΑΛΙΣΤΙΚΉ ΤΑΧΥΤΗΤΑ 5
7. TASK 07 – ΑΝΆΛΥΣΗ ΕΠΙΒΙΒΆΣΕΩΝ ΣΤΟ ΧΡΟΝΙΚΌ ΠΑΡΆΘΥΡΟ 12:00–14:00 6
8. TASK 08 – ΕΝΤΟΠΙΣΜΌΣ ΠΙΘΑΝΏΝ SHARED TRIPS 7
9. TASK 09 – ΣΤΑΤΙΣΤΙΚΉ ΑΝΆΛΥΣΗ ΑΝΆ PICKUP ZONE 8
10. TASK 10 – ΧΩΡΙΚΉ ΑΝΆΛΥΣΗ ΠΥΚΝΌΤΗΤΑΣ ΕΠΙΒΙΒΆΣΕΩΝ ΜΕ ΠΛΈΓΜΑ 2 ΚΜ × 2 ΚΜ9
11. TASK 11 – ΔΗΜΙΟΥΡΓΊΑ ΕΜΠΛΟΥΤΙΣΜΈΝΩΝ ΠΙΝΆΚΩΝ TRIPS ΚΑΙ TAXIZONES1 ... 11

ΔΕΙΓΜΑ ΕΓΓΡΑΦΩΝ ΠΙΝΑΚΑ TRIPS 12

12. TASK 12 – ΣΥΧΝΌΤΕΡΑ ΖΕΥΓΗ ΠΡΟΈΛΕΥΣΗΣ–ΠΡΟΟΡΙΣΜΟΎ 12

13. TASK 13 – ΑΝΆΛΥΣΗ ΦΙΛΟΔΩΡΗΜΆΤΩΝ ΚΑΙ ΕΠΙΒΑΤΩΝ ΑΝΆ PICKUP ZONE 13

14. TASK 14 – ΠΡΌΒΛΕΨΗ ΣΥΝΟΛΙΚΟΎ ΚΌΣΤΟΥΣ ΤΑΞΙΔΙΟΎ 14

1. Task 01 – Δημιουργια Βασης Δεδομενων και Φορτωση Δεδομενων

Το πρώτο βήμα της εργασίας αφορούσε τη δημιουργία της βάσης δεδομένων σε περιβάλλον PostgreSQL με υποστήριξη PostGIS, καθώς και την εισαγωγή των δεδομένων των διαδρομών των κίτρινων ταξί της Νέας Υόρκης. Επιπλέον, φορτώθηκε ο πίνακας των taxi zones, ώστε κάθε κωδικός τοποθεσίας (LocationID) να μπορεί να συσχετιστεί με τη ζώνη, τον δήμο και το αντίστοιχο service zone. Αρχικά δημιουργήθηκε η βάση δεδομένων NYCTaxiDB και στη συνέχεια εκτελέστηκαν τα απαραίτητα SQL ερωτήματα για τη δημιουργία των πινάκων TripRecords και TaxiZones. Τα δεδομένα των διαδρομών είχαν προηγουμένως μετατραπεί από μορφή Parquet σε CSV. Έπειτα έγινε προσαρμογή των ονομάτων των στηλών ώστε να είναι συμβατά με το σχήμα της βάσης δεδομένων, ενώ οι χρονικές μεταβλητές pickup_dt και dropoff_dt μετατράπηκαν σε τύπο ημερομηνίας και ώρας.

Κατηγορία	Τιμή
Βάση δεδομένων	PostgreSQL / PostGIS
Πίνακας ταξιδιών	TripRecords
Πίνακας ζωνών	TaxiZones
Αρχείο ταξιδιών	data.csv
Αρχείο ζωνών	taxi_zone_lookup.csv
Μέθοδος φόρτωσης	Pandas + execute_values()
Χρονικές στήλες	pickup_dt, dropoff_dt

Η διαδικασία ολοκληρώθηκε με επιτυχία και στη βάση δεδομένων αποθηκεύτηκαν συνολικά 3.724.889 εγγραφές ταξιδιών. Το μέγεθος αυτό προσφέρει ένα ιδιαίτερα πλούσιο και αντιπροσωπευτικό σύνολο δεδομένων για περαιτέρω επεξεργασία.

2. Task 02 – Δημιουργια Γεωμετρικων Σημειων Pickup και Dropoff

Στόχος του δεύτερου task ήταν η αντιστοίχιση των κωδικών ζωνών pu_location_id και do_location_id με πραγματικές γεωγραφικές θέσεις. Για τον σκοπό αυτό δημιουργήθηκαν οι στήλες pickup_location και dropoff_location, οι οποίες αποθηκεύουν τη γεωμετρία των σημείων επιβίβασης και αποβίβασης των διαδρομών. Αρχικά διαβάστηκε το shapefile των taxi zones με τη χρήση της βιβλιοθήκης GeoPandas.

Για κάθε ζώνη υπολογίστηκε το κεντροειδές (centroid) του αντίστοιχου πολυγώνου, ώστε να προκύψει ένα αντιπροσωπευτικό γεωγραφικό σημείο. Ο υπολογισμός πραγματοποιήθηκε στο σύστημα αναφοράς EPSG:2263, το οποίο είναι κατάλληλο για χωρικές πράξεις και προσφέρει μεγαλύτερη ακρίβεια στους γεωμετρικούς υπολογισμούς. Στη συνέχεια τα παραγόμενα σημεία μετατράπηκαν στο σύστημα EPSG:4326, το οποίο χρησιμοποιείται για αποθήκευση και απεικόνιση γεωγραφικών συντεταγμένων.

Τα κεντροειδή αποθηκεύτηκαν προσωρινά στον πίνακα zone_centroids_tmp - καθώς όταν το δοκιμάσαμε απευθείας δεν υπήρξε αποτέλεσμα - και στη συνέχεια πραγματοποιήθηκε

ενημέρωση του πίνακα TripRecords, ώστε κάθε διαδρομή να αποκτήσει γεωμετρικά σημεία για το pickup και το dropoff.

Αποτελέσματα

Μέτρηση	Τιμή
Συνολικές εγγραφές	3.724.889
Εγγραφές με έγκυρη γεωμετρία pickup και dropoff	3.699.638
Εγγραφές χωρίς πλήρη γεωμετρία	25.251
Τελικό SRID	4326

Η διαδικασία ολοκληρώθηκε με επιτυχία για τη συντριπτική πλειονότητα των εγγραφών, καθώς περισσότερες από 3,6 εκατομμύρια διαδρομές απέκτησαν έγκυρα γεωμετρικά σημεία. Οι εγγραφές που παρέμειναν χωρίς πλήρη γεωμετρία σχετίζονται με ειδικές ή μη καθορισμένες ζώνες, όπως οι κωδικοί 264 και 265, οι οποίοι δεν διαθέτουν αντίστοιχη πολυγωνική αναπαράσταση στο shapefile. Επομένως, η απουσία γεωμετρίας στις συγκεκριμένες περιπτώσεις θεωρείται αναμενόμενη και δεν επηρεάζει την ορθότητα της διαδικασίας.

3. Task 03 – Φιλτραρισμα Εγγραφων Εκτος του Bounding Box της Νεας Υορκης

Στόχος του τρίτου task ήταν ο εντοπισμός και η απομάκρυνση εγγραφών που δεν ανήκουν στη γεωγραφική περιοχή της Νέας Υόρκης. Με αυτόν τον τρόπο διασφαλίζεται ότι οι επόμενες χωρικές αναλύσεις θα πραγματοποιηθούν αποκλειστικά σε έγκυρα δεδομένα που βρίσκονται εντός της περιοχής μελέτης. Για τον έλεγχο των εγγραφών χρησιμοποιήθηκε το ορθογώνιο γεωγραφικό πλαίσιο (bounding box) που ορίστηκε στην εκφώνηση της εργασίας. Οι γεωμετρίες των σημείων pickup και dropoff εξετάστηκαν ως προς τη θέση τους σε σχέση με τα καθορισμένα γεωγραφικά όρια.

Οι εγγραφές που δεν διέθεταν έγκυρη γεωμετρία ή των οποίων τα σημεία βρίσκονταν εκτός του επιτρεπόμενου γεωγραφικού πεδίου απομακρύνθηκαν από τον πίνακα δεδομένων. Με αυτόν τον τρόπο διατηρήθηκαν μόνο οι διαδρομές που μπορούν να συσχετιστούν με ασφάλεια με την περιοχή της Νέας Υόρκης.

Όριο	Τιμή
Ελάχιστο latitude	40.4774
Μέγιστο latitude	40.9176
Ελάχιστο longitude	-74.2591
Μέγιστο longitude	-73.7004
CRS	EPSG:4326

Αποτελέσματα

Μέτρηση	Τιμή
Εγγραφές πριν το φιλτράρισμα	3.724.889
Εγγραφές μετά το φιλτράρισμα	3.699.638
Εγγραφές που αφαιρέθηκαν	25.251

Η εφαρμογή του γεωγραφικού φίλτρου οδήγησε στην απομάκρυνση 25.251 εγγραφών, οι οποίες είτε δεν διέθεταν έγκυρα γεωμετρικά στοιχεία (βλ. προηγούμενα) είτε δεν μπορούσαν να ενταχθούν με αξιοπιστία στα γεωγραφικά όρια της Νέας Υόρκης. Η διαδικασία αυτή συνέβαλε στη βελτίωση της ποιότητας του συνόλου δεδομένων, περιορίζοντας την παρουσία ακραίων ή λανθασμένων τιμών που θα μπορούσαν να επηρεάσουν τα αποτελέσματα των επόμενων χωρικών αναλύσεων.

4. TASK 04 – ΑΦΑΙΡΕΣΗ ΕΓΓΡΑΦΩΝ ΜΕ ΛΑΝΘΑΣΜΕΝΗ ΧΡΟΝΙΚΗ ΣΕΙΡΑ

Σκοπός του task ήταν ο εντοπισμός ταξιδιών στα οποία η ώρα αποβίβασης προηγείται της ώρας επιβίβασης. Τέτοιες εγγραφές είναι λογικά αδύνατες και πρέπει να αφαιρεθούν.

Εφαρμόστηκε SQL έλεγχος στη μορφή:

dropoff_dt < pickup_dt

Πρώτα μετρήθηκαν οι προβληματικές εγγραφές και στη συνέχεια διαγράφηκαν από τον πίνακα TripRecords. Βρέθηκε μόνο μία εγγραφή με λανθασμένη χρονική σειρά. Αυτό δείχνει ότι το dataset είναι σε μεγάλο βαθμό χρονικά συνεπές.

5. TASK 05 – ΑΦΑΙΡΕΣΗ ΔΙΠΛΟΤΥΠΩΝ ΚΑΙ ΣΧΕΔΟΝ ΔΙΠΛΟΤΥΠΩΝ ΕΓΓΡΑΦΩΝ

Στόχος του συγκεκριμένου task ήταν ο εντοπισμός και η απομάκρυνση εγγραφών που αντιστοιχούσαν στο ίδιο ή σχεδόν στο ίδιο ταξίδι. Σύμφωνα με τις προδιαγραφές της εργασίας, ως σχεδόν διπλότυπες θεωρούνται οι διαδρομές που έχουν το ίδιο σημείο επιβίβασης και αποβίβασης (pickup και dropoff zone), ενώ οι χρόνοι επιβίβασης διαφέρουν κατά το πολύ 60 δευτερόλεπτα.

Για την ανίχνευση των διπλότυπων εγγραφών, τα δεδομένα ομαδοποιήθηκαν με βάση το ζεύγος των ζωνών:

(pu_location_id, do_location_id)

Στη συνέχεια, οι εγγραφές κάθε ομάδας ταξινομήθηκαν χρονολογικά σύμφωνα με την τιμή του πεδίου pickup_dt. Με χρήση SQL window functions συγκρίστηκε ο χρόνος επιβίβασης κάθε ταξιδιού με τον χρόνο της αμέσως προηγούμενης εγγραφής της ίδιας ομάδας.

Όταν η χρονική διαφορά ήταν μικρότερη ή ίση με 60 δευτερόλεπτα, η εγγραφή χαρακτηριζόταν ως σχεδόν διπλότυπη και αφαιρούνταν από το σύνολο δεδομένων. Σε κάθε περίπτωση διατηρήθηκε μόνο η πρώτη εμφάνιση, η οποία θεωρήθηκε η έγκυρη καταγραφή του ταξιδιού.

Παράμετροι/ Αποτελέσματα

Παράμετρος	**Τιμή**
Κριτήριο ταύτισης	Ίδιο pu_location_id και do_location_id
Χρονικό όριο	60 δευτερόλεπτα
Στρατηγική	Διατήρηση της πρώτης εμφάνισης
Μέθοδος υλοποίησης	SQL Window Functions
Εγγραφές που αφαιρέθηκαν	358.690

Η διαδικασία αποκάλυψε σημαντικό αριθμό διπλότυπων ή σχεδόν διπλότυπων εγγραφών στο αρχικό σύνολο δεδομένων, καθώς αφαιρέθηκαν συνολικά 358.690 ταξίδια. Το εύρημα αυτό δείχνει ότι υπήρχαν αρκετές επαναλαμβανόμενες καταγραφές, οι οποίες θα μπορούσαν να επηρεάσουν αρνητικά τα αποτελέσματα της ανάλυσης. Η απομάκρυνσή τους συνέβαλε στη βελτίωση της ποιότητας των δεδομένων και στη δημιουργία ενός πιο αξιόπιστου συνόλου για τις επόμενες φάσεις της ανάλυσης και οδηγώντας σε πιο ρεαλιστικά και ακριβή συμπεράσματα.

6. TASK 06 – ΑΦΑΙΡΕΣΗ ΕΓΓΡΑΦΩΝ ΜΕ ΜΗ ΡΕΑΛΙΣΤΙΚΗ ΤΑΧΥΤΗΤΑ

Στόχος του έκτου task ήταν ο εντοπισμός και η απομάκρυνση ταξιδιών που παρουσίαζαν μη ρεαλιστικές τιμές ταχύτητας. Τέτοιου είδους εγγραφές συνήθως προκύπτουν από σφάλματα στην καταγραφή της διάρκειας ή της απόστασης ενός ταξιδιού και μπορούν να επηρεάσουν σημαντικά την αξιοπιστία των αποτελεσμάτων που προκύπτουν από τη στατιστική και γεωχωρική ανάλυση.

Για κάθε διαδρομή υπολογίστηκε αρχικά η διάρκειά της σε ώρες, χρησιμοποιώντας τη διαφορά μεταξύ των χρονικών στιγμών pickup_dt και dropoff_dt.

Η απόσταση του ταξιδιού ήταν διαθέσιμη σε μίλια και μετατράπηκε σε χιλιόμετρα με τη χρήση του συντελεστή μετατροπής 1 mile = 1.609 km (περ.)

Στη συνέχεια υπολογίστηκε η μέση ταχύτητα κάθε διαδρομής ως το πηλίκο της απόστασης (σε χιλιόμετρα) προς τη διάρκεια του ταξιδιού (σε ώρες).

Από το σύνολο δεδομένων αφαιρέθηκαν οι εγγραφές που πληρούσαν μία από τις παρακάτω συνθήκες:

- Η διάρκεια του ταξιδιού ήταν μικρότερη ή ίση με μηδέν.
- Η υπολογισμένη ταχύτητα ξεπερνούσε τα 120 km/h.

Οι συνθήκες αυτές χρησιμοποιήθηκαν για τον εντοπισμό πιθανών λαθών ή ακραίων τιμών που δεν ανταποκρίνονται σε πραγματικές συνθήκες κυκλοφορίας.

Παράμετρος	**Τιμή**

Μετατροπή miles → km	1.609
Μέγιστη αποδεκτή ταχύτητα	120 km/h
Κριτήριο απόρριψης	speed > 120 km/h
Κριτήριο απόρριψης	duration ≤ 0
Εγγραφές που αφαιρέθηκαν	39.912
Εγγραφές πριν την αφαίρεση	3.340.947
Εγγραφές μετά την αφαίρεση	3.301.035

Η εφαρμογή του συγκεκριμένου φίλτρου οδήγησε στην απομάκρυνση 39.912 εγγραφών που παρουσίαζαν μη ρεαλιστικές τιμές ταχύτητας ή προβληματικές χρονικές καταγραφές. Σε ένα πυκνοκατοικημένο αστικό περιβάλλον όπως η Νέα Υόρκη, η διατήρηση ταχυτήτων άνω των 120 km/h θεωρείται εξαιρετικά απίθανη για τα ταξί που εκτελούν καθημερινές διαδρομές. Επομένως, οι συγκεκριμένες εγγραφές είναι πιθανό να οφείλονται σε σφάλματα μέτρησης ή καταγραφής. Η αφαίρεσή τους συνέβαλε στη βελτίωση της ποιότητας και της αξιοπιστίας του συνόλου δεδομένων, εξασφαλίζοντας πιο ακριβή αποτελέσματα στις επόμενες φάσεις της ανάλυσης.

7. Task 07 – Ανάλυση Επιβιβάσεων στο Χρονικό Παράθυρο 12:00–14:00

Στόχος του συγκεκριμένου task ήταν η μελέτη της ταξιδιωτικής δραστηριότητας κατά το χρονικό διάστημα από τις 12:00 έως τις 14:00 της 15ης Ιανουαρίου 2026. Πιο συγκεκριμένα, επιδιώχθηκε ο υπολογισμός του συνολικού αριθμού ταξιδιών που ξεκίνησαν μέσα σε αυτό το δίωρο, καθώς και ο εντοπισμός της ζώνης με τις περισσότερες επιβιβάσεις.

Για την εξαγωγή των αποτελεσμάτων εφαρμόστηκε χρονικό φίλτρο στη στήλη pickup_dt, ώστε να επιλεγούν μόνο οι διαδρομές που ξεκίνησαν μεταξύ 12:00 και 14:00 της συγκεκριμένης ημερομηνίας.

Στη συνέχεια πραγματοποιήθηκε ομαδοποίηση των εγγραφών με βάση το pu_location_id, προκειμένου να υπολογιστεί ο αριθμός των επιβιβάσεων ανά ζώνη. Τέλος, τα αποτελέσματα συνδέθηκαν με τον πίνακα TaxiZones, ώστε κάθε κωδικός ζώνης να αντιστοιχηθεί με το πραγματικό όνομα της περιοχής.

Παράμετρος	Τιμή
Ημερομηνία	15/01/2026
Ώρα έναρξης	12:00
Ώρα λήξης	14:00
Πεδίο φιλτραρίσματος	pickup_dt

Αποτελέσματα

Μέτρηση	Τιμή
Συνολικά ταξίδια	11.432
Ζώνη με τις περισσότερες επιβιβάσεις	Upper East Side South
Zone ID	237
Αριθμός επιβιβάσεων	563

Κατά το εξεταζόμενο δίωρο καταγράφηκαν συνολικά 11.432 διαδρομές ταξί. Η ζώνη Upper East Side South εμφάνισε τη μεγαλύτερη συγκέντρωση επιβιβάσεων, με 563 ταξίδια να ξεκινούν από την περιοχή αυτή.

Το αποτέλεσμα θεωρείται λογικό, καθώς η συγκεκριμένη περιοχή βρίσκεται στο Manhattan και χαρακτηρίζεται από έντονη εμπορική και οικιστική δραστηριότητα. Η υψηλή πυκνότητα κατοίκων, εργαζομένων και επισκεπτών δημιουργεί αυξημένη ζήτηση για μετακινήσεις, ιδιαίτερα κατά τις μεσημεριανές ώρες, όταν πραγματοποιούνται μετακινήσεις για εργασία, αγορές ή αναψυχή.

8. TASK 08 – ΕΝΤΟΠΙΣΜΟΣ ΠΙΘΑΝΩΝ SHARED TRIPS

Σκοπός του task ήταν η ανίχνευση ζευγών ταξιδιών που ξεκίνησαν σχεδόν ταυτόχρονα και από σχεδόν το ίδιο σημείο.

Δύο ταξίδια θεωρήθηκαν υποψήφια shared trip όταν:

- και τα δύο είχαν τουλάχιστον έναν επιβάτη,
- η χρονική διαφορά pickup ήταν μικρότερη από 5 λεπτά,
- η χωρική απόσταση pickup ήταν μικρότερη από 50 μέτρα.

Η χωρική απόσταση υπολογίστηκε με τη συνάρτηση:

```
ST_DWithin(...)
```

Για να αποφευχθεί διπλή καταμέτρηση χρησιμοποιήθηκε:

```
a.trip_id < b.trip_id
```

Παράμετρος	**Τιμή**
Μέγιστη απόσταση	50 m
Μέγιστη χρονική διαφορά	5 λεπτά
passenger_count	> 0
Shared-trip pairs	95.422

Ο μεγάλος αριθμός πιθανών shared trips δείχνει ότι πολλές διαδρομές ξεκινούν από γειτονικά σημεία σε παρόμοιες χρονικές στιγμές. Αυτό υποδηλώνει σημαντικές δυνατότητες βελτιστοποίησης μέσω ride-sharing.

9. TASK 09 – ΣΤΑΤΙΣΤΙΚΗ ΑΝΑΛΥΣΗ ΑΝΑ PICKUP ZONE

Στόχος του task ήταν η μελέτη των χαρακτηριστικών των διαδρομών ανά ζώνη επιβίβασης (pickup zone) κατά το χρονικό διάστημα που εξετάστηκε. Μέσα από τη στατιστική ανάλυση επιδιώχθηκε να αναδειχθούν διαφορές μεταξύ των περιοχών ως προς τις αποστάσεις των διαδρομών, το συνολικό κόστος και τον αριθμό των ταξιδιών που πραγματοποιήθηκαν.

Για κάθε τιμή του πεδίου pu_location_id υπολογίστηκαν βασικά περιγραφικά στατιστικά στοιχεία σχετικά με την απόσταση και το συνολικό ποσό χρέωσης των διαδρομών.

Συγκεκριμένα υπολογίστηκαν:

- Η ελάχιστη απόσταση ταξιδιού.
- Η μέση απόσταση ταξιδιού.
- Η μέγιστη απόσταση ταξιδιού.
- Το ελάχιστο συνολικό ποσό χρέωσης.
- Το μέσο συνολικό ποσό χρέωσης.
- Το μέγιστο συνολικό ποσό χρέωσης.
- Το πλήθος των ταξιδιών που ξεκίνησαν από κάθε ζώνη.

Οι υπολογισμοί πραγματοποιήθηκαν με χρήση συναρτήσεων συγκέντρωσης (aggregation functions) σε SQL.

Αποτελέσματα

Μέτρηση	**Τιμή**
Pickup zones με καταγεγραμμένη δραστηριότητα	210
Χρονικό παράθυρο ανάλυσης	12:00 – 14:00

Ενδεικτικό δείγμα αποτελεσμάτων

Zone ID	**Zone**	**Borough**	**Trips**	**Min Distance (mi)**	**Avg Distance (mi)**	**Max Distance (mi)**	**Min Total ($)**	**Avg Total ($)**	**Max Total ($)**
237	Upper East Side South	Manhattan	563	0.00	2.15	20.90	-21.05	23.82	145.99
161	Midtown Center	Manhattan	542	0.00	2.57	22.00	-28.75	25.85	168.64
236	Upper East Side North	Manhattan	531	0.00	2.14	22.00	8.70	23.28	139.66
170	Murray Hill	Manhattan	397	0.00	2.42	19.82	-56.61	25.20	138.53
162	Midtown East	Manhattan	379	0.00	2.50	20.59	-46.95	25.71	175.68
140	Lenox Hill East	Manhattan	369	0.00	2.78	24.90	9.10	25.50	76.68

Zone ID	Zone	Borough	Trips	Min Distance (mi)	Avg Distance (mi)	Max Distance (mi)	Min Total ($)	Avg Total ($)	Max Total ($)
234	Union Sq	Manhattan	331	0.00	1.96	19.93	-13.35	24.75	148.81
142	Lincoln Square East	Manhattan	325	0.00	2.11	21.41	-13.35	22.69	152.57
186	Penn Station/Madison Sq West	Manhattan	321	0.00	2.29	24.46	-31.55	25.86	131.08
239	Upper West Side South	Manhattan	308	0.00	2.22	25.10	-18.20	22.87	

Η ανάλυση έδειξε ότι οι ζώνες με τη μεγαλύτερη δραστηριότητα κατά το χρονικό διάστημα 12:00–14:00 βρίσκονται κυρίως στο Manhattan. Η περιοχή Upper East Side South κατέγραψε τον μεγαλύτερο αριθμό επιβιβάσεων (563 ταξίδια), ενώ οι μέσες αποστάσεις κυμάνθηκαν περίπου μεταξύ 2 και 3 μιλίων. Το μέσο συνολικό κόστος των διαδρομών κυμάνθηκε μεταξύ 22 και 26 δολαρίων. Παρατηρούνται επίσης αρνητικές ελάχιστες τιμές στο total_amount σε ορισμένες ζώνες, γεγονός που πιθανόν οφείλεται σε διορθώσεις χρεώσεων, επιστροφές χρημάτων ή ειδικές λογιστικές εγγραφές του συστήματος TLC.

10. Task 10 – Χωρική Ανάλυση Πυκνότητας Επιβιβάσεων με Πλέγμα 2 km × 2 km

Στόχος του συγκεκριμένου task ήταν η διερεύνηση της χωρικής κατανομής των επιβιβάσεων ταξί κατά το χρονικό διάστημα 15/01/2026 από τις 12:00 έως τις 14:00. Για την επίτευξη αυτού του στόχου δημιουργήθηκε ένα κανονικό πλέγμα τετραγωνικών κελιών διαστάσεων 2 km × 2 km που κάλυπτε ολόκληρη την περιοχή μελέτης. Στη συνέχεια υπολογίστηκε ο αριθμός των επιβιβάσεων που αντιστοιχούσε σε κάθε κελί, ώστε να εντοπιστούν οι περιοχές με τη μεγαλύτερη συγκέντρωση μετακινήσεων.

Η ανάλυση πραγματοποιήθηκε εντός του γεωγραφικού πλαισίου που ορίστηκε από τα ακόλουθα όρια:

Παράμετρος	Τιμή
Min Longitude	-74.2591
Max Longitude	-73.7004
Min Latitude	40.4774
Max Latitude	40.9176

Αρχικά ανακτήθηκαν από τη βάση δεδομένων όλα τα σημεία επιβίβασης (pickup points) που αντιστοιχούσαν στο χρονικό διάστημα μεταξύ 12:00 και 14:00.

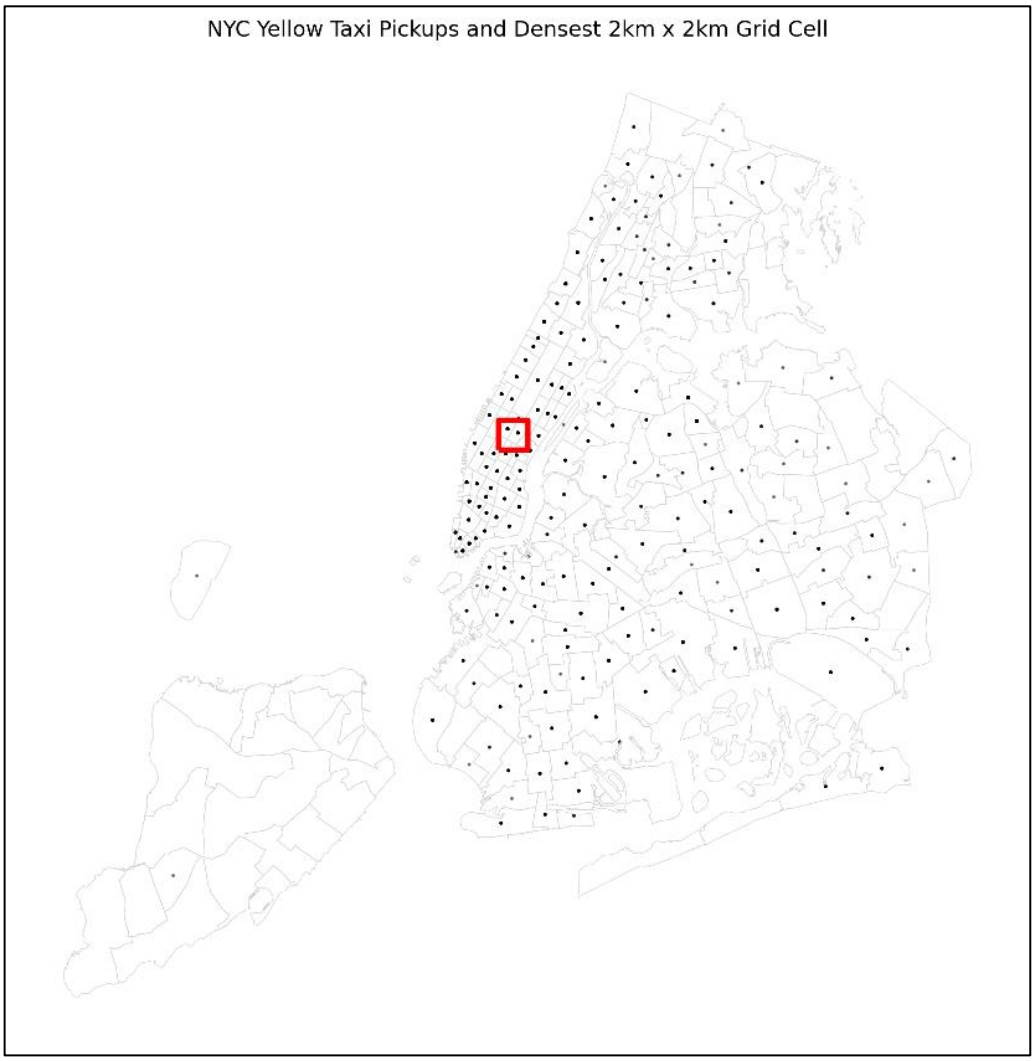
Οι γεωμετρίες των σημείων μετατράπηκαν από το σύστημα αναφοράς EPSG:4326 στο EPSG:3857, ώστε οι αποστάσεις να εκφράζονται σε μέτρα και να είναι δυνατή η δημιουργία πλέγματος σταθερού μεγέθους.

Στη συνέχεια κατασκευάστηκε ένα κανονικό πλέγμα μη επικαλυπτόμενων τετραγώνων διαστάσεων 2.000 × 2.000 μέτρων, με αφετηρία την κάτω αριστερή γωνία του bounding box. Για κάθε σημείο επιβίβασης πραγματοποιήθηκε χωρική αντιστοίχιση (Spatial Join), ώστε να προσδιοριστεί το κελί στο οποίο ανήκε. Τέλος, υπολογίστηκε το πλήθος των επιβιβάσεων ανά κελί και εντοπίστηκε το κελί με τη μεγαλύτερη συγκέντρωση ταξιδιών.

Παράμετρος	**Τιμή**
CRS εισόδου	EPSG:4326
CRS ανάλυσης	EPSG:3857
Μέγεθος κελιού	2 km × 2 km
Spatial Predicate	within

Μέτρηση	**Τιμή**
Συνολικά κελιά πλέγματος	1.056
Πυκνότερο κελί	656
Επιβιβάσεις στο πυκνότερο κελί	1.378

Figure 1. Δείγμα περίπου 20.000 σημείων επιβίβασης και απεικόνιση του πυκνότερου κελιού του πλέγματος 2 km × 2 km με κόκκινο περίγραμμα.



Η ανάλυση έδειξε ότι το κελί με τη μεγαλύτερη συγκέντρωση επιβιβάσεων βρίσκεται στην περιοχή του κεντρικού Manhattan, όπου καταγράφηκαν συνολικά 1.378 pickups μέσα στο εξεταζόμενο δίωρο. Το αποτέλεσμα είναι αναμενόμενο, καθώς η συγκεκριμένη περιοχή αποτελεί έναν από τους σημαντικότερους πυρήνες οικονομικής, εμπορικής και τουριστικής δραστηριότητας της Νέας Υόρκης.

11. TASK 11 – ΔΗΜΙΟΥΡΓΙΑ ΕΜΠΛΟΥΤΙΣΜΕΝΩΝ ΠΙΝΑΚΩΝ TRIPS ΚΑΙ TAXIZONES1

Στόχος του συγκεκριμένου task ήταν η δημιουργία μιας πιο ολοκληρωμένης και κατάλληλα δομημένης βάσης δεδομένων, η οποία να υποστηρίζει αποτελεσματικά τόσο χωρικές όσο και στατιστικές αναλύσεις. Στο πλαίσιο του εμπλουτισμού της βάσης δεδομένων δημιουργήθηκαν δύο νέοι πίνακες: Trips και TaxiZones1.

Πίνακας Trips

Ο πίνακας Trips σχεδιάστηκε ώστε να συγκεντρώνει όλα τα απαραίτητα χαρακτηριστικά κάθε διαδρομής σε μία ενιαία δομή. Εκτός από τα βασικά στοιχεία του ταξιδιού, περιλαμβάνει:

- Γεωμετρία σημείου επιβίβασης (pickup location).
- Γεωμετρία σημείου αποβίβασης (dropoff location).
- Διάρκεια διαδρομής.
- Υπολογισμένη ταχύτητα ταξιδιού.
- Οικονομικά στοιχεία, όπως χρεώσεις και φιλοδωρήματα.

Πίνακας TaxiZones1

Για τη δημιουργία του πίνακα TaxiZones1, το shapefile των taxi zones διαβάστηκε με τη χρήση της βιβλιοθήκης GeoPandas και συνδυάστηκε με το αρχείο taxi_zone_lookup.csv. Η σύνδεση πραγματοποιήθηκε μέσω του πεδίου LocationID, επιτρέποντας τον εμπλουτισμό κάθε γεωγραφικής οντότητας με πρόσθετα περιγραφικά χαρακτηριστικά.

Ο τελικός πίνακας περιλαμβάνει για κάθε ζώνη:

- Κωδικό Location ID.
- Borough.
- Zone.
- Service Zone.
- Γεωμετρία πολυγώνου.

Δείγμα εγγραφών πίνακα Trips

trip_id	vendor_id	pickup_dt	dropoff_dt
3724867	2	2026-01-31 23:12:12	2026-01-31 23:45:25
3724868	2	2026-01-31 23:05:19	2026-01-31 23:24:28
3724869	2	2026-01-31 23:38:40	2026-02-01 00:03:09
3724870	2	2026-01-31 23:17:18	2026-01-31 23:25:24
3724871	1	2026-01-31 23:21:54	2026-01-31 23:56:25

Ενδεικτικό δείγμα πέντε εγγραφών από τον εμπλουτισμένο πίνακα Trips. Οι στήλες pickup_location και dropoff_location αποθηκεύονται ως γεωμετρίες τύπου Point σε μορφή WKB/EWKB (EPSG:4326) και δεν εμφανίζονται πλήρως για λόγους αναγνωσιμότητας.

location_id	Borough	Zone	Service Zone
1	EWR	Newark Airport	EWR
2	Queens	Jamaica Bay	Boro Zone
3	Bronx	Allerton/Pelham Gardens	Boro Zone
4	Manhattan	Alphabet City	Yellow Zone
5	Staten Island	Arden Heights	Boro Zone

Ενδεικτικό δείγμα πέντε εγγραφών από τον πίνακα TaxiZones1. Ο πίνακας περιλαμβάνει το αναγνωριστικό της ζώνης (location_id), το borough, το όνομα της ζώνης (zone), την κατηγορία εξυπηρέτησης (service_zone) και το πολυγωνικό γεωμετρικό περίγραμμα κάθε ζώνης, το οποίο αποθηκεύεται σε πεδίο geometry και δεν εμφανίζεται στον πίνακα για λόγους αναγνωσιμότητας.

12. TASK 12 – ΣΥΧΝΟΤΕΡΑ ΖΕΥΓΗ ΠΡΟΕΛΕΥΣΗΣ–ΠΡΟΟΡΙΣΜΟΥ

Στόχος του συγκεκριμένου task ήταν η αναγνώριση των πιο συχνών ζευγών προέλευσης–προορισμού (Origin–Destination Pairs) στο σύνολο των διαθέσιμων διαδρομών. Η ανάλυση αυτή επιτρέπει την κατανόηση των βασικών προτύπων μετακίνησης των επιβατών και την ανάδειξη των περιοχών μεταξύ των οποίων παρατηρείται η μεγαλύτερη ταξιδιωτική ροή.

Για τον προσδιορισμό της ζώνης προέλευσης και προορισμού κάθε διαδρομής πραγματοποιήθηκε χωρική αντιστοίχιση των σημείων επιβίβασης και αποβίβασης με τα πολύγωνα των taxi zones. Η διαδικασία βασίστηκε στη χωρική συνάρτηση **ST_Within()**, η οποία ελέγχει εάν ένα σημείο βρίσκεται εντός ενός συγκεκριμένου πολυγώνου.

Αφού ολοκληρώθηκε η αντιστοίχιση, οι διαδρομές ομαδοποιήθηκαν με βάση το ζεύγος:

Pickup Zone → Dropoff Zone

Για κάθε συνδυασμό υπολογίστηκε το συνολικό πλήθος ταξιδιών, ενώ τα αποτελέσματα ταξινομήθηκαν κατά φθίνουσα σειρά, ώστε να εντοπιστούν οι πιο δημοφιλείς διαδρομές.

Top 5 Origin–Destination Pairs

Rank	Pickup Zone	Dropoff Zone	Trips
1	Upper East Side South	Upper East Side North	9451
2	Upper East Side North	Upper East Side South	8481
3	Upper East Side South	Upper East Side South	8408
4	Upper East Side North	Upper East Side North	8389
5	Midtown Center	Upper East Side South	6519

Τα αποτελέσματα δείχνουν ότι οι συχνότερες διαδρομές πραγματοποιούνται κυρίως μεταξύ γειτονικών περιοχών του Manhattan. Η μεγαλύτερη συγκέντρωση μετακινήσεων παρατηρείται μεταξύ των περιοχών Upper East Side South και Upper East Side North, γεγονός που υποδηλώνει έντονη τοπική κινητικότητα στο κεντρικό τμήμα της πόλης.

13. Task 13 – Ανάλυση Φιλοδωρημάτων και Επιβατών ανα Pickup Zone

Στόχος του συγκεκριμένου task ήταν η διερεύνηση της συμπεριφοράς των επιβατών στις διαφορετικές περιοχές της Νέας Υόρκης, με βάση τα χαρακτηριστικά των διαδρομών που ξεκινούν από κάθε pickup zone. Για τον σκοπό αυτό υπολογίστηκαν τρεις βασικοί δείκτες: το μέσο ποσό φιλοδωρήματος, το ποσοστό των ταξιδιών με δύο ή περισσότερους επιβάτες και το συνολικό πλήθος διαδρομών ανά ζώνη.

Η ανάλυση αυτή επιτρέπει την καλύτερη κατανόηση των προτύπων μετακίνησης και αναδεικνύει πιθανές διαφοροποιήσεις στη συμπεριφορά των επιβατών ανάλογα με τα χαρακτηριστικά κάθε περιοχής.

Αρχικά, τα σημεία επιβίβασης συσχετίστηκαν χωρικά με τις γεωγραφικές ζώνες του πίνακα TaxiZones1 μέσω της συνάρτησης ST_Within(), ώστε κάθε διαδρομή να αντιστοιχιστεί στη σωστή pickup zone.

Στη συνέχεια υπολογίστηκαν για κάθε ζώνη τα εξής στατιστικά μεγέθη:

- Μέσο φιλοδώρημα (Average Tip Amount), το οποίο προέκυψε από τον μέσο όρο της μεταβλητής *tip_amount*.
- Ποσοστό ταξιδιών με τουλάχιστον δύο επιβάτες, το οποίο εκφράζει το ποσοστό των διαδρομών όπου ο αριθμός επιβατών ήταν μεγαλύτερος ή ίσος με δύο.
- Συνολικό πλήθος ταξιδιών, το οποίο αντιστοιχεί στον αριθμό των διαδρομών που ξεκίνησαν από κάθε ζώνη.

Τέλος, οι περιοχές ταξινομήθηκαν κατά φθίνουσα σειρά με βάση το πλήθος ταξιδιών, ώστε να αναδειχθούν οι ζώνες με τη μεγαλύτερη κινητικότητα.

Top 10 Pickup Zones

Pickup Zone	Borough	Average Tip ($)	Trips ≥ 2 Passengers (%)	Total Trips
JFK Airport	Queens	8.836	27.695	129.191
Midtown Center	Manhattan	2.925	15.018	120.226
Upper East Side South	Manhattan	2.597	13.502	116.311
Upper East Side North	Manhattan	2.561	12.440	109.676
Penn Station/Madison Sq West	Manhattan	2.994	15.978	94.834
Midtown East	Manhattan	2.957	12.665	93.660
Times Sq/Theatre District	Manhattan	3.074	21.499	92.349
Lincoln Square East	Manhattan	2.622	15.668	91.705
East Village	Manhattan	1.834	11.298	88.236
Union Sq	Manhattan	2.351	12.145	85.268

Η περιοχή JFK Airport εμφανίζει τη μεγαλύτερη κινητικότητα, συγκεντρώνοντας 129.191 ταξίδια, ενώ παράλληλα παρουσιάζει και το υψηλότερο μέσο φιλοδώρημα, το οποίο ανέρχεται στα 8,84 δολάρια. Το εύρημα αυτό είναι αναμενόμενο, καθώς οι διαδρομές που συνδέονται με το αεροδρόμιο είναι συνήθως μεγαλύτερης διάρκειας και υψηλότερου κόστους σε σύγκριση με τις τυπικές αστικές μετακινήσεις Παρατηρείται επίσης ότι οι περισσότερες από τις ζώνες με τον μεγαλύτερο αριθμό επιβιβάσεων βρίσκονται στο Manhattan. Η εικόνα αυτή αντανακλά τη μεγάλη συγκέντρωση κατοίκων, εργαζομένων, επιχειρήσεων και τουριστικών δραστηριοτήτων που χαρακτηρίζει τη συγκεκριμένη περιοχή Ιδιαίτερο ενδιαφέρον παρουσιάζει η ζώνη Times Square/Theatre District, όπου σχεδόν ένα στα πέντε ταξίδια πραγματοποιείται από δύο ή περισσότερους επιβάτες. Το υψηλό αυτό ποσοστό συνδέεται πιθανότατα με την έντονη τουριστική δραστηριότητα και τη συχνή μετακίνηση ομάδων επισκεπτών. Αντίθετα, περιοχές όπως το East Village εμφανίζουν χαμηλότερα ποσοστά πολυπρόσωπων διαδρομών, γεγονός που υποδηλώνει μεγαλύτερη παρουσία μεμονωμένων επιβατών. (Στον κώδικα εμφανίζονται όλες οι ζώνες, εδώ βάλαμε τις 10 μεγαλύτερες)

14. Task 14 – Πρόβλεψη Συνολικού Κόστους Ταξιδιού

Στόχος του bonus task ήταν η ανάπτυξη ενός μοντέλου μηχανικής μάθησης για την πρόβλεψη του συνολικού κόστους μιας διαδρομής ταξί (total_amount). Η δυνατότητα εκτίμησης του ναύλου πριν από την ολοκλήρωση του ταξιδιού μπορεί να αποδειχθεί ιδιαίτερα χρήσιμη τόσο για τους επιβάτες όσο και για τους παρόχους υπηρεσιών μεταφοράς, καθώς επιτρέπει καλύτερο προγραμματισμό και ακριβέστερη πρόβλεψη του κόστους μετακίνησης.

Για την εκπαίδευση του μοντέλου χρησιμοποιήθηκαν χαρακτηριστικά που περιγράφουν τη χωρική, χρονική και λειτουργική διάσταση κάθε διαδρομής.

Feature	Περιγραφή

pu_location_id	Ζώνη επιβίβασης
do_location_id	Ζώνη αποβίβασης
passenger_count	Αριθμός επιβατών
trip_distance	Απόσταση διαδρομής
pickup_hour	Ώρα επιβίβασης
pickup_dow	Ημέρα εβδομάδας

Πριν από την εκπαίδευση πραγματοποιήθηκε καθαρισμός των δεδομένων, με απομάκρυνση εγγραφών που περιείχαν μηδενικές ή αρνητικές τιμές στο πεδίο total_amount, καθώς αυτές αντιστοιχούσαν κυρίως σε επιστροφές χρημάτων, διορθωτικές χρεώσεις ή άλλες μη κανονικές συναλλαγές.

Οι κατηγορικές μεταβλητές μετατράπηκαν σε δυαδικά χαρακτηριστικά μέσω της τεχνικής One-Hot Encoding, ενώ για λόγους αποδοτικότητας χρησιμοποιήθηκαν οι 25 συχνότερες pickup και dropoff zones. Το τελικό σύνολο περιλάμβανε συνολικά 54 χαρακτηριστικά.

Το dataset χωρίστηκε σε δύο υποσύνολα:

Σύνολο	Ποσοστό
Training Set	80%
Test Set	20%

Λόγω μη διαθεσιμότητας της βιβλιοθήκης scikit-learn στο περιβάλλον εκτέλεσης, υλοποιήθηκε εναλλακτική λύση γραμμικής παλινδρόμησης με χρήση της βιβλιοθήκης NumPy.

Αποτελέσματα

Μετρική	Τιμή
Μοντέλο	NumpyLinearRegressionFallback
Χαρακτηριστικά	54
MAE	5.43 $
Μέσο Κόστος Ταξιδιού	30.13 $

Το μοντέλο πέτυχε Mean Absolute Error (MAE) ίσο με 5,43 δολάρια, γεγονός που σημαίνει ότι η πρόβλεψη του κόστους αποκλίνει κατά μέσο όρο περίπου 5 δολάρια από την πραγματική τιμή. Δεδομένου ότι το μέσο κόστος ταξιδιού στο σύνολο δεδομένων είναι 30,13 δολάρια, το σχετικό σφάλμα αντιστοιχεί περίπου στο 18%.

Η επίδοση αυτή θεωρείται ικανοποιητική για ένα απλό μοντέλο γραμμικής παλινδρόμησης, το οποίο βασίζεται αποκλειστικά σε πληροφορίες σχετικά με την απόσταση, την περιοχή προέλευσης και προορισμού, τον αριθμό επιβατών και τα χρονικά χαρακτηριστικά της διαδρομής. Η μεταβλητή trip_distance αποδείχθηκε ιδιαίτερα σημαντική, καθώς συνδέεται άμεσα με τη διαμόρφωση του ναύλου. Παράλληλα, οι χωρικές μεταβλητές επέτρεψαν στο μοντέλο να αποτυπώσει διαφορές κόστους μεταξύ διαφορετικών περιοχών της πόλης.

Αξίζει να σημειωθεί ότι ο αποκλεισμός των εγγραφών με αρνητικές οικονομικές τιμές βελτίωσε αισθητά την απόδοση του μοντέλου. Στην αρχική εκδοχή της ανάλυσης το MAE ανερχόταν σε 6,33 δολάρια, ενώ μετά τον καθαρισμό των δεδομένων μειώθηκε στα 5,43 δολάρια, καταγράφοντας βελτίωση περίπου 14%.